

Pregunta 1

(a) Veamos que π_k es un estimador consistente de η_k . Consideremos tomar la esperanza condicionada a ambos lados de la igualdad, esto es

$$E \left[\sum_{i=1}^n \pi_k(X_i) X_{ij} | X_1, X_2, \dots, X_n \right] = E \left[\sum_{i=1}^n \mathbb{1}(k = Y_i) X_{ij} | X_1, X_2, \dots, X_n \right] \quad \forall k \in [K] \quad \forall j \in [d]$$

Por linealidad de la esperanza (y quitamos de la condicional lo que no dependa)

$$\sum_{i=1}^n E [\pi_k(X_i) X_{ij} | X_i] = \sum_{i=1}^n E [\mathbb{1}(k = Y_i) X_{ij} | X_i] \quad \forall k \in [K] \quad \forall j \in [d]$$

Sacando los valores que se vuelven constantes al estar condicionando se obtiene

$$\sum_{i=1}^n \pi_k(X_i) X_{ij} = \sum_{i=1}^n E [\mathbb{1}(k = Y_i) | X_i] X_{ij} \quad \forall k \in [K] \quad \forall j \in [d]$$

Pero la esperanza de una función indicatriz es simplemente la probabilidad, esto es

$$\sum_{i=1}^n \pi_k(X_i) X_{ij} = \sum_{i=1}^n P(k = Y_i) X_{ij} \quad \forall k \in [K] \quad \forall j \in [d]$$

Reemplazando por η_k

$$\sum_{i=1}^n \pi_k(X_i) X_{ij} = \sum_{i=1}^n \eta_k(X_i) X_{ij} \quad \forall k \in [K] \quad \forall j \in [d]$$

Por lo cual el predictor de bayes es un estimador consistente, justificando la heurística

(b) Primero reescribamos el problema de optimización completo

$$\begin{aligned} \max_{\pi: \mathbb{R}^d \rightarrow \Delta_K} \quad & - \sum_{i=1}^n \sum_{k=1}^K \pi_k(X_i) \ln \pi_k(X_i) \\ \text{s.t.} \quad & \pi_k(X_i) \geq 0 \quad \forall i \in [n], \forall k \in [K], \\ & \sum_{k=1}^K \pi_k(X_i) = 1 \quad \forall i \in [n], \\ & \sum_{i=1}^n \pi_k(X_i) X_{ij} = \sum_{i=1}^n \mathbb{1}(Y_i = k) X_{ij} \quad \forall k \in [K], \forall j \in [d]. \end{aligned}$$

Ahora vamos a formular el Lagrangiano, los multiplicadores de Lagrange serán $\mu_{ki} \leq 0, \gamma_i, w_{kj}$ en el mismo orden que están las restricciones anteriores, de lo que resulta

$$\begin{aligned} \mathcal{L}(\pi, \mu, \gamma, \lambda) = & - \sum_{i=1}^n \sum_{k=1}^K \pi_k(X_i) \ln \pi_k(X_i) + \sum_{i=1}^n \sum_{k=1}^K \mu_{ki} \pi_k(X_i) \\ & + \sum_{i=1}^n \gamma_i \left(\sum_{k=1}^K \pi_k(X_i) - 1 \right) + \sum_{k=1}^K \sum_{j=1}^d w_{kj} \left(\sum_{i=1}^n \pi_k(X_i) X_{ij} - \sum_{i=1}^n \mathbb{1}(Y_i = k) X_{ij} \right) \end{aligned}$$

Ahora consideremos encontrar derivadas parciales. Para encontrar el óptimo $\pi_k^*(X_i)$, tomamos la derivada parcial de \mathcal{L} respecto a $\pi_k(X_i)$ y la igualamos a cero, esto es

$$\frac{\partial \mathcal{L}}{\partial \pi_k(X_i)} = -\ln \pi_k(X_i) - 1 + \mu_{ki} + \gamma_i + \sum_{j=1}^d w_{kj} X_{ij} = 0$$

Reordenamos

$$\ln \pi_k^*(X_i) = \sum_{j=1}^d w_{kj}^* X_{ij} + \gamma_i + \mu_{ki} - 1$$

Y exponenciamos

$$\pi_k^*(X_i) = \exp \left\{ \sum_{j=1}^d w_{kj}^* X_{ij} + \gamma_i + \mu_{ki} - 1 \right\}$$

Notemos que en la función objetivo original se tiene el término $\ln \pi_k(X_i)$, el cual no está definido cuando $\pi_k(X_i) = 0$, y además se tiene que en el óptimo vimos que es función de una exponencial, por lo que nunca será $\pi_k^*(X_i) = 0$. Con lo anterior, podemos concluir que entonces $\pi_k^*(X_i) > 0$. Pero entonces, por ser holguras complementarias se tiene que $\mu_{ki} = 0$ (ya que corresponde a la variable de la restricción $\pi_k(X_i) \geq 0$ la que dijimos que se cumple de forma estricta) por lo que se tiene que

$$\pi_k^*(X_i) = \exp \left\{ \sum_{j=1}^d w_{kj}^* X_{ij} + \gamma_i - 1 \right\} = \exp \{ \langle w_k^*, X_i \rangle \} \cdot e^{\gamma_i - 1}$$

De la restricción $\sum_{k=1}^K \pi_k(X_i) = 1$ se tiene que en el óptimo

$$\sum_{k=1}^K \exp \{ \langle w_k^*, X_i \rangle \} \cdot e^{\gamma_i - 1} = 1$$

Factorizamos

$$e^{\gamma_i - 1} \sum_{k=1}^K \exp \{ \langle w_k^*, X_i \rangle \} = 1$$

Por lo tanto

$$e^{\gamma_i - 1} = \frac{1}{\sum_{k=1}^K \exp\{\langle w_k^*, X_i \rangle\}}$$

Reemplazando en $\pi_k^*(X_i)$ se obtiene

$$\pi_k^*(X_i) = \frac{\exp\{\langle w_k^*, X_i \rangle\}}{\sum_{k=1}^K \exp\{\langle w_k^*, X_i \rangle\}}$$

Demostrando lo pedido

Pregunta 2

(a) Se tiene que la función de log-verosimilitud de los datos corresponde por definición a

$$L(S|\pi) = \sum_{i=1}^n \ln \pi_{Y_i}(X_i)$$

Sustituyendo $\pi_{Y_i}(X_i)$ por la parametrización encontrada se obtiene que

$$L(S|\pi) = \sum_{i=1}^n \ln \left(\frac{\exp(\langle w_{Y_i}, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} \right) = \sum_{i=1}^n \left(\langle w_{Y_i}, X_i \rangle - \ln \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right) \right)$$

Esto es

$$-\frac{1}{n} L(S|\pi) = -\mathcal{R}_S(W) = \frac{1}{n} \sum_{i=1}^n \left(\langle w_{Y_i}, X_i \rangle - \ln \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right) \right)$$

Demostrando que la log-verosimilitud dada una hipótesis $\pi \in F$ es proporcional a $-\mathcal{R}_S(W)$, tal como queríamos demostrar. Ahora veamos que \mathcal{R}_S es convexa

Primero veamos que $g(x) = \ln \left(\sum_{k=1}^K e^{x_k} \right)$ es convexa. Sea $x, y \in \mathbb{R}^k$, entonces

$$g(\lambda x + (1 - \lambda)y) = \ln \left(\sum_{k=1}^K e^{\lambda x_k + (1-\lambda)y_k} \right) = \ln \left(\sum_{k=1}^K e^{\lambda x_k} e^{(1-\lambda)y_k} \right)$$

Aplicando la desigualdad de Holder y teniendo en cuenta que la función \ln es creciente, resulta en

$$\ln \left(\sum_{k=1}^K e^{\lambda x_k} e^{(1-\lambda)y_k} \right) \leq \ln \left(\left(\sum_{k=1}^K e^{\lambda x_k \cdot \frac{1}{\lambda}} \right)^\lambda \left(\sum_{k=1}^K e^{(1-\lambda)y_k \cdot \frac{1}{1-\lambda}} \right)^{(1-\lambda)} \right)$$

Pero simplificando y separando la multiplicación del logaritmo por sumas fuera se obtiene

$$g(\lambda x + (1 - \lambda)y) \leq \lambda \ln \left(\sum_{k=1}^K e^{x_k} \right) + (1 - \lambda) \ln \left(\sum_{k=1}^K e^{y_k} \right) = \lambda g(x) + (1 - \lambda)g(y)$$

Demostrando así la convexidad de g por definición. Pero entonces $\ln \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)$ es una composición de una función lineal con una función convexa, resultando en una función convexa. Notemos que la función $-\langle w_{Y_i}, X_i \rangle$ es lineal y por tanto convexa. Así

$$\mathcal{R}_S = \frac{1}{n} \sum_{i=1}^n \left(-\langle w_{Y_i}, X_i \rangle + \ln \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right) \right)$$

Es una suma de funciones convexas, resultando en una función convexa

Como la función objetivo es convexa entonces el problema de minimizar $\mathcal{R}_S(W)$ es un problema convexo si Ω es convexo y cerrado.

(b) Para encontrar la constante de Lipchitz de la función vamos a calcular su derivada. Consideremos la función restringida a una sola muestra

$$\mathcal{R}_S^i = -\langle w_{Y_i}, X_i \rangle + \ln \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)$$

Calculemos su derivada con respecto al vector de pesos correspondiente a la clase j

$$\frac{\partial \mathcal{R}_S^i}{\partial w_j} = \begin{cases} -X_i + \frac{\exp(\langle w_j, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} X_i & \text{si } j = Y_i, \\ \frac{\exp(\langle w_j, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} X_i & \text{si } j \neq Y_i. \end{cases}$$

Por lo que la derivada (considerando todas las clases y muestras) corresponden a lo siguiente.

$$\frac{\partial \mathcal{R}_S}{\partial w} = \frac{1}{n} \sum_{i=1}^n \left(\left(\frac{\exp(\langle w_1, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} - \mathbb{1}_{(Y_i=1)} \right) X_i, \dots, \left(\frac{\exp(\langle w_K, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} - \mathbb{1}_{(Y_i=K)} \right) X_i \right)$$

Para verificar que $\mathcal{R}_S(w)$ es Lipschitz basta con verificar que la norma de $\nabla \mathcal{R}_S(w)$ es acotada, ya que podemos usar el teorema del valor medio.

Consideremos

$$p_k^i = \frac{\exp(\langle w_k, X_i \rangle)}{\sum_{j=1}^K \exp(\langle w_j, X_i \rangle)}.$$

Notemos que $\sum_{k=1}^K p_k^i = 1$, y además del gradiente original nos resulta

$$\frac{\partial \mathcal{R}_S}{\partial w} = \frac{1}{n} \sum_{i=1}^n ((p_1^i - \mathbb{1}_{(Y_i=1)}) X_i, \dots, (p_k^i - \mathbb{1}_{(Y_i=K)}) X_i)$$

Para encontrar la constante de Lipchitz podemos encontrar la norma de este gradiente, esto es

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 = \left\| \frac{1}{n} \sum_{i=1}^n ((p_1^i - \mathbb{1}_{(Y_i=1)}) X_i, \dots, (p_k^i - \mathbb{1}_{(Y_i=K)}) X_i) \right\|_2$$

Sacando constante y usando la desigualdad triangular

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 \leq \frac{1}{n} \sum_{i=1}^n \|((p_1^i - \mathbb{1}_{(Y_i=1)}) X_i, \dots, (p_k^i - \mathbb{1}_{(Y_i=K)}) X_i)\|_2$$

También podemos separar los vectores en dos, en la parte con p y la parte con la función indicatriz, y nuevamente usando la desigualdad triangular resulta en (en el vector con la función indicatriz debiera tener signo negativo, pero sale de la norma con signo positivo)

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 \leq \frac{1}{n} \sum_{i=1}^n (\|(p_1^i X_i, \dots, p_k^i X_i)\|_2 + \|(\mathbb{1}_{(Y_i=1)} X_i, \dots, \mathbb{1}_{(Y_i=K)} X_i)\|_2)$$

Del vector de las indicatrices hay exactamente una entrada que es 1 y el resto 0, por lo que su norma es equivalente a la de la norma del vector X_i . Para el vector del lado izquierdo lo podemos separar entre los distintos bloques y reescribimos su norma

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 \leq \frac{1}{n} \sum_{i=1}^n \left(\sqrt{\sum_{k=1}^K \|p_k^i X_i\|_2^2} + \|X_i\|_2 \right)$$

Podemos sacar la constante p_k^i de la norma, y factorizar lo que no depende de k de la sumatoria, resultando en

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 \leq \frac{1}{n} \sum_{i=1}^n \left(\sqrt{\|X_i\|_2^2 \sum_{k=1}^K p_k^i} + \|X_i\|_2 \right)$$

Pero recordando que $\sum_{k=1}^K p_k^i = 1$ nos resulta en

$$\left\| \frac{\partial \mathcal{R}_S}{\partial w} \right\|_2 \leq \frac{1}{n} \sum_{i=1}^n (\|X_i\|_2 + \|X_i\|_2) = \frac{2}{n} \sum_{i=1}^n \|X_i\|_2$$

Lo cual no depende de w , por lo que la derivada es acotada. Con esto, se demuestra que la función es Lipchitz y su constante en la norma indicada corresponde a la encontrada, esto es, su constante es $\frac{2}{n} \sum_{i=1}^n \|X_i\|_2$

Ahora para encontrar la constante de suavidad derivemos una vez más para encontrar el Hessiano. Recordemos el gradiente e ignoremos el término $-X_i$ cuando $j = Y_i$ ya que al derivar una vez más al no depender de w se perderá, entonces tenemos que

$$\frac{\partial \mathcal{R}_S^i}{\partial w_j} = \frac{\exp(\langle w_j, X_i \rangle)}{\sum_{k=1}^K \exp(\langle w_k, X_i \rangle)} X_i$$

Derivemos con respecto a w_l , nos resulta usando la regla del cociente que

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = \frac{\left(\frac{\partial}{\partial w_l} \exp(\langle w_j, X_i \rangle) \right) \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right) - \left(\exp(\langle w_j, X_i \rangle) \right) \left(\frac{\partial}{\partial w_l} \sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)}{\left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)^2} X_i^T$$

Primero veamos el caso si $j = l$, en este caso se tiene que

$$\frac{\partial}{\partial w_l} \exp(\langle w_j, X_i \rangle) = \exp(\langle w_j, X_i \rangle) X_i$$

Y además

$$\frac{\partial}{\partial w_l} \sum_{k=1}^K \exp(\langle w_k, X_i \rangle) = \exp(\langle w_l, X_i \rangle) X_i$$

Reemplazando

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = \frac{(\exp(\langle w_j, X_i \rangle) X_i) \left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right) - (\exp(\langle w_j, X_i \rangle)) (\exp(\langle w_l, X_i \rangle) X_i)}{\left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)^2} X_i^T$$

Factorizando nos resulta

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = \frac{(\exp(\langle w_j, X_i \rangle) X_i) \left(\sum_{k=1, k \neq l}^K \exp(\langle w_k, X_i \rangle) \right)}{\left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)^2} X_i^T$$

De lo que resulta

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = p_j^i (1 - p_j^i) X_i X_i^T$$

Ahora veamos el caso si $j \neq l$, en este caso se tiene que

$$\frac{\partial}{\partial w_l} \exp(\langle w_j, X_i \rangle) = 0$$

Y además

$$\frac{\partial}{\partial w_l} \sum_{k=1}^K \exp(\langle w_k, X_i \rangle) = \exp(\langle w_l, X_i \rangle) X_i$$

Reemplazando

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = \frac{-(\exp(\langle w_j, X_i \rangle)) (\exp(\langle w_l, X_i \rangle) X_i)}{\left(\sum_{k=1}^K \exp(\langle w_k, X_i \rangle) \right)^2} X_i^T$$

De lo que resulta

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = -p_j^i p_l^i X_i X_i^T$$

Entonces, en términos generales se tiene que

$$\frac{\partial^2 \mathcal{R}_S^i}{\partial w_j \partial w_l} = p_j^i (\mathbb{1}_{(j=l)} - p_l^i) X_i X_i^T$$

Sea $H \in \mathbb{R}^{K \times d}$ arbitrario, entonces se tiene que

$$\langle \nabla^2 \mathcal{R}_S(w) H, H \rangle = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^K \sum_{l=1}^K p_j^i (\mathbb{1}_{(j=l)} - p_l^i) (H_j^T X_i) (H_l^T X_i)$$

De la desigualdad de Cauchy-Schwarz se tiene que

$$p_j^i (\mathbb{1}_{(j=l)} - p_l^i) (H_j^T X_i) (H_l^T X_i) \leq p_j^i \|X_i\|^2 \|H_j\| \|H_l\|$$

Notando que $\sum_{k=1}^K p_k^i = 1$, se tiene que

$$\langle \nabla^2 \mathcal{R}_S(w) H, H \rangle \leq \max_i \|X_i\|^2 \|H\|_F^2$$

Por lo tanto, se concluye que la función es suave con constante de suavidad

$$C = \max_i \|X_i\|^2$$

Pregunta 3

(a) Primero veamos que $P(\epsilon) \leq N(\epsilon)$. Sea $\mathcal{P} \subseteq \Omega$ un ϵ -empaquetamiento máximo y $\mathcal{C} \subseteq \Omega$ un ϵ -cubrimiento mínimo. Sea $p \in \mathcal{P}$, como \mathcal{C} es un ϵ -cubrimiento entonces existe un $c \in \mathcal{C}$ tal que $\|c - p\|_2 \leq \epsilon$. Sea $p' \in \mathcal{P}$ con $p' \neq p$, se tiene por la desigualdad triangular que $\|p' - p\|_2 \leq \|p' - c\|_2 + \|c - p\|_2$. Reordenando se tiene que $\|p' - c\|_2 \geq \|p' - p\|_2 - \|c - p\|_2 > 2\epsilon - \epsilon = \epsilon$ (Recordemos que $\|p' - p\|_2 > 2\epsilon$ ya que las bolas centradas en p y p' con radio ϵ no se intersectan). Entonces, para cada $p \in \mathcal{P}$ existe un $c \in \mathcal{C}$ que lo contiene en su bola de tamaño ϵ y dicho c no incluye a ningún otro $p' \in \mathcal{P} \setminus \{p\}$ en dicha bola, por lo que podemos concluir que $|\mathcal{P}| \leq |\mathcal{C}|$ y entonces $P(\epsilon) \leq N(\epsilon)$.

Ahora veamos que $N(2\epsilon) \leq P(\epsilon)$. Sea $\mathcal{P} \subseteq \Omega$ un ϵ -empaquetamiento. Si \mathcal{P} no es un 2ϵ -cubrimiento, entonces hay un punto $x \in \Omega$ tal que $\|x - p\|_2 \geq 2\epsilon$ para todo $p \in \mathcal{P}$, por lo que el conjunto $\mathcal{P} \cup \{x\}$ también es un ϵ -empaquetamiento. Por lo tanto, cualquier ϵ -empaquetamiento máximo debe también ser un 2ϵ -cubrimiento. Por lo tanto, se concluye que un 2ϵ -cubrimiento mínimo debe tener menor o igual cardinalidad que el ϵ -empaquetamiento máximo.

Con esto podemos concluir que

$$N(2\epsilon) \leq P(\epsilon) \leq N(\epsilon)$$

Demostrando lo pedido

(b) Primero veamos que $\left(\frac{R}{\epsilon}\right)^m \leq N(\epsilon)$. Notemos que el hiper-volumen de la hiper-esfera $\mathcal{B}(0, R)$ es $V(\mathcal{B}(0, R)) = c_m R^m$ donde c_m es una constante que depende de la dimensión. Además tenemos que el hiper-volumen de una hiper-esfera $\mathcal{B}(x, \epsilon)$ es $V(\mathcal{B}(x, \epsilon)) = c_m \epsilon^m$. Entonces si yo tengo L bolas de tamaño ϵ , el volumen V que ocupan está acotado por $V \leq L \cdot c_m \epsilon^m$. Y como yo quiero que cubran volumen de $c_m R^m$ tenemos la expresión

$$c_m R^m \leq L \cdot c_m \epsilon^m \rightarrow \left(\frac{R}{\epsilon}\right)^m \leq L$$

Demostrando que $\left(\frac{R}{\epsilon}\right)^m \leq N(\epsilon)$, es una constante que es lo mínimo que tenemos que pedir para cubrir el espacio.

Ahora veamos que $N(\epsilon) \leq \left(1 + \frac{2R}{\epsilon}\right)^m$. Consideremos un $\frac{\epsilon}{2}$ -empaquetamiento máximo \mathcal{P} , se tiene entonces que

$$\mathcal{B}\left(p, \frac{\epsilon}{2}\right) \subseteq \mathcal{B}\left(0, R + \frac{\epsilon}{2}\right) \quad \forall p \in \mathcal{P}$$

Por lo tanto, como cada uno es subconjunto entonces la unión también debe serlo

$$\bigcup_{p \in \mathcal{P}} \mathcal{B}\left(p, \frac{\epsilon}{2}\right) \subseteq \mathcal{B}\left(0, R + \frac{\epsilon}{2}\right)$$

Por lo que al ser un subconjunto el volumen debe ser menor o igual

$$V\left(\bigcup_{p \in \mathcal{P}} \mathcal{B}\left(p, \frac{\epsilon}{2}\right)\right) \leq V\left(\mathcal{B}\left(0, R + \frac{\epsilon}{2}\right)\right)$$

Por ser un empaquetamiento, entonces todas las bolas son disjuntas, por lo que

$$\sum_{p \in \mathcal{P}} V\left(\mathcal{B}\left(p, \frac{\epsilon}{2}\right)\right) \leq V\left(\mathcal{B}\left(0, R + \frac{\epsilon}{2}\right)\right)$$

Usando la fórmula de volumen encontrada anteriormente

$$\sum_{p \in \mathcal{P}} c_m \frac{\epsilon^m}{2^m} = |\mathcal{P}| c_m \frac{\epsilon^m}{2^m} = P\left(\frac{\epsilon}{2}\right) c_m \frac{\epsilon^m}{2^m} \leq c_m \left(R + \frac{\epsilon}{2}\right)^m$$

Entonces

$$P\left(\frac{\epsilon}{2}\right) \leq \left(\frac{R + \frac{\epsilon}{2}}{\frac{\epsilon}{2}}\right)^m = \left(1 + \frac{2R}{\epsilon}\right)^m$$

Y por lo demostrado en la parte a se tiene que

$$N(\epsilon) \leq P\left(\frac{\epsilon}{2}\right) \leq \left(1 + \frac{2R}{\epsilon}\right)^m$$

Concluyendo lo pedido. En resumen, se tiene que

$$\left(\frac{R}{\epsilon}\right)^m \leq N(\epsilon) \leq \left(1 + \frac{2R}{\epsilon}\right)^m$$

(c) Por la desigualdad estudiada en clases

$$N_{LB}(2L\epsilon, \mathcal{G}, L_1(D)) \leq N(L\epsilon, \mathcal{G}, L_\infty(D))$$

Pero como $\phi(W, (X, Y))$ es Lipchitz con constante $\|X\|_2$, entonces usando la norma ℓ_∞ dicha constante resulta en $\sup_{x \in \mathcal{X}} (\|x\|_2) = 2L$. Por lo tanto, si existe un ϵ -cubrimiento de Ω , entonces al usar dichos puntos como parámetros de la función estamos consiguiendo un $L\epsilon$ -cubrimiento de \mathcal{G} , esto es, \mathcal{N} es un $L\epsilon$ -cubrimiento de \mathcal{G} . Por lo que se concluye que

$$N_{LB}(2L\epsilon, \mathcal{G}, L_1(D)) \leq N(L\epsilon, \mathcal{G}, L_\infty(D)) \leq |\mathcal{N}|$$

Tal como queríamos demostrar

Así, si consideramos un cubrimiento ϵ de Ω , por lo demostrado en el punto anterior el número N de funciones a considerar es de a lo más

$$N \leq \left(1 + \frac{2R}{\epsilon}\right)^{Kd}$$

Y por tanto la complejidad muestral dado el δ corresponde a

$$O\left(\left(1 + \frac{2R}{\epsilon}\right)^{Kd} \log\left(\frac{1}{\delta}\right)\right)$$

Mostrando que la regresión logística es PAC-aprendible